분석 보고서

신용카드 고객 클러스터링 분석

Mission 15 | DA12기 4팀 전미정

"대부분의 예산에서 전체 항목의 약 20%가 예산 총액의 80%를 차지했다.

그 항목을 확실히 이해하면 많은 돈을 절약할 수 있다."

– 한스 로슬링, 〈팩트풀니스〉 중

이번 Mission 15에 〈팩트풀니스〉의 인용구를 거꾸로 적용한다면, 소수의 항목이 전체 항목의 대부분에 기여하는 매출이 될 수도 있다는 말이다. 이번 분석은 이상치 처리를 하지 않고 클러스터링을 진행했는데, 끝까지 이 결정을 밀어붙인 이유는 바로 이상치로 판단되는 소수의 극단값이 이 데이터가 말하는 바를 가장 극적으로 이야기해준다고 믿었기 때문이다.

1. 들어가며 — 왜 고객을 나누는가

Mission 14에서 나는 처음으로 비지도 학습을 경험했다. 정답이 없는 세계에서 데이터 스스로 군집을 만들어내는 과정이 신기했다. 그런데 한편으로는 불안했다. 모델이 내놓은 숫자가 맞는지 어떻게 알 수 있을까?

Mission 15는 같은 데이터, 같은 방법론이다. 신용카드 고객 약 9,000명의 6개월 행동 데이터로 고객을 세분화하고, 그 군집에 맞는 마케팅 전략을 제안하는 것이 목표다. Mission 14와 다른 점이 있다면, 이번에는 분석 전에 먼저 가설을 세웠다는 것이다.

가설은 두 가지 였다.

가설 1 — "혼합 구매 여부가 고소비 고객을 가르는 핵심 변수다", 그리고 가설 2 — "VVIP는 혼합 구매 + 고결제력 + 저현금서비스의 조합이며, 혼합 구매자 중 일부가 VVIP 승급 후보다". 이 두 가설을 데이터로 검증하는 것이 이번 분석의 중심이었다.

분석을 마치고 보니, 가설을 먼저 세우는 것이 분석의 흐름을 완전히 바꾼다는 것을 알게 됐다. 숫자를 쫓는 것이 아니라, 숫자에게 질문을 던지는 방식으로.

2. 데이터를 읽기 전에 한 일들

2-1. 결측치, 기계적 처리를 거부하다

데이터를 열어보니 결측치가 두 곳에 있었다. CREDIT_LIMIT 1건, MINIMUM_PAYMENTS 313건. 처음에는 자연스럽게 중앙값으로 채우려 했다. 그것이 일반적인 방법이니까.

그런데 잠깐 멈췄다. 중앙값으로 채운다는 것은 무엇을 의미하는가? 결제 이력이 있는 고객과 결제 이력이 없는 고객을 같은 숫자로 처리한다는 뜻이다. 이것은 데이터에 거짓말을 하는 것이 아닐까?

그래서 결측 313건의 특성을 먼저 살펴봤다. PAYMENTS, BALANCE, PURCHASES, TENURE 기준으로 기술통계량을 확인했더니, PAYMENTS 중앙값이 0이었다. 즉 결측 고객 대부분이 아직 한 번도 결제하지 않은 사람들이었다. 결제를 하지 않은 사람에게 최소결제액이 있을 리 없다. 0이 맞다.

하지만 PAYMENTS 〉 0인 73건은 달랐다. 결제는 했는데 최소결제액이 없다는 것은 데이터 신뢰성 문제였다. 이 73건은 삭제했다.

> *기계적으로 중위값을 채우면 분석에 중요한 클러스터가 사라질 수 있다.*
> *결측치도 맥락이 있다. 그 맥락을 읽어야 한다.*

최종 결과: 8,950행 → 8,876행. 74행이 줄었지만, 남은 데이터는 더 신뢰할 수 있었다.

2-2. 이상치를 살리기로 한 이유

박스플롯으로 이상치를 확인했다. 8개 금액 계열 컬럼 모두에서 오른쪽으로 길게 늘어진 꼬리가 보였다. PURCHASES max 49,039, CASH_ADVANCE max 47,137. 교과서라면 IQR 기준으로 클리핑하거나 삭제하라고 할 것이다.

이상치는 이미 Mission 14를 할 때도 계속 고민했던 부분이다. 이 데이터는 신용카드 고객 데이터다. 이 숫자들의 주인을 생각해봤다. CASH_ADVANCE가 47,137인 고객은 노이즈일까?

아니다. 6개월 동안 현금서비스를 4만 7천 달러어치나 쓴 사람이다. 이 사람이야말로 '현금서비스 의존형' 군집의 핵심 구성원이다. 이 사람을 제거하면 군집 자체가 사라질 수 있다.

PURCHASES가 49,039인 고객도 마찬가지다. 이 사람이 나중에 VVIP 군집으로 분류된다. 클리핑 했다면 VVIP라는 군집 자체를 놓쳤을 것이다.

> *이상치를 살려두는 결정이 분석 전체의 방향을 바꿨다.*
> *스케일링(StandardScaler)이 극단값의 영향을 완화하면서도,*
> *그 존재는 군집 분리에 기여하도록 했다.*

3. 군집을 찾아가는 과정

3-1. k를 둘러싼 불안과 검증

Elbow Method와 Silhouette Score를 돌렸다. Elbow는 k=2~15 범위에서 뚜렷한 꺾임 없이 완만하게 내려갔다. Silhouette Score는 k=2~9 범위에서 확인했고, 결과를 보고 k=4와 k=5 두 후보를 프로파일 비교로 최종 결정하기로 했다.

k=4에서는 한 군집이 전체의 45%를 차지했다. 이 덩어리 안에 여러 유형이 섞여있다는 신호였다. k=5에서 그 덩어리가 소극적 이용형(44%), 건전 이용형(27%), 일반 활성형(16%)으로 쪼개졌다. 마케팅 전략 측면에서 이 세 군집은 완전히 다른 접근이 필요하다.

> *클러스터링을 하는 과정에서 12기 동기들과 이야기를 나누다가*
> *한 친구가 강사님과 나눈 이야기를 전해주었다.*
> *"데이터를 일반화해야 군집이 보인다"고 하셨다고 한다.*
> *갑자기 마음이 불안해졌다. 전처리를 좀더 과감하게 했어야 하는 것 아닐까?*
> *이상치를 살려둔 내 결정이 과연 맞을까?*
> *잠깐 흔들렸다. 하지만 스케일링도 곧 일반화다. 내 판단을 믿고 더 밀어붙여보기로 했다.*

3-2. PCA가 열어준 것

K-means 원본 실루엣 스코어는 0.1932였다. 계층적 클러스터링은 0.1361. 그런데 PCA 6개 주성분으로 차원 축소 후 K-means를 돌렸더니 0.2604가 나왔다.

PCA가 17개 컬럼을 6개 주성분으로 압축하면서 노이즈가 제거된 것이다. PURCHASES 계열 4개 컬럼이 서로 0.86~0.92의 상관관계를 보였는데, 이것들이 하나의 주성분으로 합쳐지면서 거리 계산의 왜곡이 줄었다.

알고리즘	실루엣 스코어	비고
K-means 원본 (k=5)	0.1932	기준 모델
계층적 클러스터링 (k=5)	0.1361	ward linkage
PCA K-means (k=5)	0.2604	최종 선정

VVIP 군집도 더 엄격하게 분리됐다. 원본 K-means에서 86명이었던 VVIP가 PCA K-means에서 30명으로 줄었다. 핵심 극단값만 남겨진 것이다. 계층적 클러스터링에서는 23명이었다. 세 모델 모두 VVIP가 소수라는 것, 그리고 그들이 나머지와 완전히 다른 차원이라는 것은 일치했다.

DBSCAN과 GMM은 이번에는 다루지 않았다. Mission 14에서 여러번 진행하면서 이미 확인한 결과 때문이다. 밀도가 불균일하고 극단값이 많은 이 데이터의 특성상, 밀도 기반(DBSCAN)이나 타원형 군집 가정(GMM)보다 거리 기반 K-means가 더 잘 맞는다는 것은 이미 확인됐다.

4. 다섯 가지 군상 — 최종 군집 프로파일

PCA K-means k=5 기준, 8,876명의 신용카드 고객은 다음 다섯 유형으로 나뉜다.

군집	페르소나	인원	비율	핵심 특징
0	건전 이용형	3,025명	34%	중간구매, 낮은 현금서비스, 전액결제 0.27
1	현금서비스 의존형	1,202명	14%	고잔액(4,493), 고현금서비스(4,526), 전액결제 0.04
2	VVIP	30명	0.3%	최고구매(24,958), 최고한도(15,570), 전액결제 0.48
3	소극적 이용형	3,877명	44%	저잔액, 저구매(280), 저한도(3,356)
4	일반 활성형	742명	8%	중간잔액(2,685), 중간구매(4,796), 중간한도(8,438)

군집 너머의 이야기

소극적 이용형(44%) — 카드가 있지만 거의 안 쓴다. 비상용이거나 주력 카드가 따로 있는 사람들. 이들에게 카드사는 수익을 내지 못하고 있다.

현금서비스 의존형(14%) — 카드를 소비 도구가 아닌 단기 부채 수단으로 쓴다. PURCHASES가 거의 0이고 CASH_ADVANCE가 압도적이다. 이 군집은 이자 수익은 높지만 연체 리스크도 높다.

VVIP(0.3%, 30명) — 모든 그래프에서 오른쪽 끝에 홀로 위치한다. 구매액 24,958은 전체 상위 0.2%다. 이들의 현금서비스 중앙값은 0 — 카드를 완전히 소비 도구로만 쓴다.

건전 이용형(34%) — 작게 쓰고 잘 갚는다. 카드사 입장에서 이자 수익이 거의 없는 우량 고객이다. 마케팅 전략이 완전히 달라야 하는 군집이다.

일반 활성형(8%) — 중간 어딘가. 소비도 결제도 평균적이지만, VVIP로 가는 잠재력이 있는 군집이기도 하다.

5. 가설 검증 — 구매 방식으로 읽는 소비 계층

5-1. 가설 1 — 혼합 구매가 고소비를 가른다

구매 방식을 일시불/할부/혼합/현금전용으로 분류하는 코드를 짰다. 원래 무구매 유형도 포함한 5분류를 계획했지만, 데이터를 확인해보니 구매도 현금서비스도 전혀 없는 고객이 0명이었다.

이 발견이 흥미로웠다. 이 데이터의 모든 고객은 최소 하나의 카드 활동 이력이 있다. 카드를 발급받았지만 한 번도 쓰지 않은 고객은 이미 이 데이터에서 걸러졌거나, 처음부터 없었다는 뜻이다.

구매 방식	인원	비율	PURCHASES 평균	CREDIT_LIMIT 평균	전액결제 비율
혼합	2,769명	31%	2,271	5,741	0.19
일시불	1,857명	21%	789	4,525	0.10
현금전용	2,034명	23%	0	4,037	0.04
할부	2,216명	25%	542	3,377	0.26

혼합 구매자의 PURCHASES 평균(2,271)은 할부(542)의 4배, 일시불(789)의 3배다. CREDIT_LIMIT도 5,741로 가장 높다. 혼합 구매 여부가 소비력 계층을 가른다는 가설이 확인됐다.

할부 고객이 전액결제 비율(0.26)이 가장 높다는 점도 흥미롭다. 소비는 적지만 성실하게 갚는다. 카드사 입장에서 이자 수익은 낮지만 신용 리스크도 낮은 건전한 고객군이다.

> *구매 방식은 단순한 결제 습관이 아니다.혼합 → 카드를 소비 극대화 도구로 / 할부 → 분산 결제 수단으로 / 현금전용 → 단기 부채 수단으로 / 일시불 → 즉시 결제 수단으로 활용한다.*

5-2. 가설 2 — VVIP 승급 경로를 찾아서

분석 중에 읽고 있던 책 팩트풀니스 5장 크기 본능에서 이런 문장을 발견했다.

> *수치가 달랑 하나만 있으면 오판하기 쉬우니 의심해야 한다.*
> *항상 비교하라.*
> *어떤 수로 나눠보면 더없이 좋다.*
> *— 한스 로슬링, 〈팩트풀니스〉*

VVIP가 30명이라는 숫자를 처음 봤을 때, 솔직히 고작 30명이라는 생각이 들었다. 전체 8,876명 중 0.3%다. 크기 본능이 작동한 것이다. 그런데 이 숫자를 나눠봤다.

VVIP + 일반 활성형 772명, 전체의 8.7%가 전체 구매액의 48.1%를 차지한다. 나머지 91.3%의 고객이 구매액의 51.9%를 만든다. 로슬링이 말한 파레토 구조가 이 데이터에서도 작동하고 있었다.

> *8.7%의 고객 → 전체 구매액의 48.1%*
> *91.3%의 고객 → 전체 구매액의 51.9%*
> *30명은 작은 숫자가 아니었다. 비교하기 전까지는.*

VVIP 30명의 특성을 파악했다. PURCHASES 24,958(전체 상위 0.2%), CREDIT_LIMIT 15,570(전체 상위 1.5%). 그런데 놀라운 점은 PRC_FULL_PAYMENT 중앙값이 0이고, CASH_ADVANCE 중앙값도 0이었다.

VVIP를 정의하는 것은 전액결제 비율이 아니었다. 순수하게 구매력(PURCHASES)과 결제 능력(PAYMENTS), 신용한도(CREDIT_LIMIT)였다. 이 사실을 확인하고 나서야 승급 후보군의 조건을 제대로 설계할 수 있었다.

처음 설정한 조건은 너무 느슨했다. 혼합 구매 + 상위 25% 소비 + 상위 25% 전액결제로 뽑은 후보군의 PURCHASES 평균이 VVIP의 16% 수준밖에 되지 않았다. 이건 승급 후보가 아니라 그냥 일반 고객이었다.

조건을 두 차례 정교화했다.

최종 조건: 혼합 구매 + PURCHASES 상위 10% + CREDIT_LIMIT 상위 10% + PAYMENTS 상위 10% + CASH_ADVANCE = 0. 이렇게 뽑은 후보군이 70명이었다.

지표	VVIP (30명)	승급 후보군 (70명)	비율
PURCHASES	24,958	12,328	49%
CREDIT_LIMIT	15,570	14,599	94%
PAYMENTS	25,179	11,725	47%
CASH_ADVANCE	1,859	0	더 낮음

한도는 VVIP의 94% 수준으로 근접했다. 한도가 막혀서 못 쓰는 게 아니다. 능력은 있는데 아직 소비를 덜 하고 있는 고객들이다.

> *승급의 핵심 조건은 전액결제 비율이 아니라 소비 규모를 키우는 것이다.*
> *이 70명에게는 혜택 강화보다 소비 활성화 마케팅이 더 효과적이다.*

6. 비즈니스 인사이트 및 마케팅 전략

팩트풀니스의 80/20 법칙은 마케팅 예산 배분에 직접 적용된다. 〈팩트풀니스〉의 저자는 말한다.

> *여러 항목을 나열한 긴 목록을 받아본 적이 있는가?*
> *그중 가장 큰 항목 몇 개를 찾아 그것부터 처리하라.*
> *그 몇 개가 나머지를 모두 합친 것보다 더 중요할 가능성이 높다.*
> *— 한스 로슬링, 〈팩트풀니스〉*

이 데이터에서 가장 큰 항목은 VVIP + 일반 활성형이다. 전체의 8.7%이지만 구매액의 48.1%를 만든다. 나머지 91.3%에 균등하게 마케팅 예산을 쓰는 것이 크기 본능이고, 8.7%를 먼저 처리하는 것이 사실충실성이다. 만약 내가 마케팅 담당자라면 절반 가까운 매출에 기여하는 VVIP + 일반 활성형 그룹에 마케팅 예산을 좀더 쓸 것 같다.

6-1. 군집별 전략

🔴 VVIP (cluster 2 / 30명 / 0.3%)

- 카드사 수익의 핵심. 이탈 1명의 비용이 매우 크다.
- 프리미엄 멤버십 전용 혜택 — 공항 라운지, 컨시어지 서비스
- 신용한도 자동 상향 검토
- 전담 고객 관리 — 이탈 방지 최우선

🟠 일반 활성형 (cluster 4 / 742명 / 8%)

- VVIP 승급 가능성이 가장 높은 성장 군집. 한도가 충분하고 혼합 구매 패턴을 보인다.
- 캐시백/포인트 혜택 강화로 소비 규모 확대 유도
- 특히 승급 후보군 70명은 집중 관리 — 개인화 혜택 제공

🟡 건전 이용형 (cluster 0 / 3,025명 / 34%)

- 이자 수익이 적지만 신용 리스크도 낮다. 이탈 방지가 중요한 군집.
- 전액결제 고객 대상 포인트/마일리지 혜택으로 충성도 강화
- 할부 유도 프로모션으로 이자 수익 창출 시도
- 생활 밀착형 혜택 — 식품, 교통, 통신 영역

🔵 소극적 이용형 (cluster 3 / 3,877명 / 44%)

- 전체의 44%이지만 카드 활용도가 가장 낮다. 수익 기여도 최하위.
- 소액 결제 혜택 — 편의점, 대중교통, 커피 등 생활 소비
- 첫 구매 캐시백 등 활성화 프로모션으로 첫 번째 습관 만들기
- 주력 카드 전환 유도 타겟 마케팅

🟢 현금서비스 의존형 (cluster 1 / 1,202명 / 14%)

- 단기 이자 수익은 높지만 연체 리스크 존재. 양면성이 있는 군집.
- 현금서비스 의존도 완화를 위한 소액 대출 상품 안내
- 리볼빙 결제 유도로 연체 리스크 관리
- 재무 건전성 개선을 위한 금융 교육 콘텐츠 제공

6-2. 구매 방식별 전략

구매 방식	고객 특성	마케팅 방향
혼합 (31%)	최상위 소비, 카드 극대화 활용	고소비 보상 — 프리미엄 포인트, 해외 혜택
할부 (25%)	건전 저소비, 높은 전액결제	할부 수수료 면제, 생활형 혜택 강화
일시불 (21%)	중상위, 즉시 결제 선호	일시불 리워드, 대형 구매 캐시백
현금전용 (23%)	구매 없음, 유동성 취약	소비 전환 유도, 금융 상품 연계

7. 나오며 — 숫자가 말하지 않는 것

이번 분석을 마치고 가장 많이 생각한 것은, 클러스터링이 결국 '사람의 유형을 읽는 일'이라는 것이다. 알고리즘은 도구다. 어떤 가설을 세우고, 어떤 맥락으로 군집을 해석하느냐가 분석의 품질을 결정한다.

결측치를 기계적으로 처리하지 않겠다는 결정, 이상치를 살려두겠다는 결정, k를 결정하기에 결정적인 꺾임이 안 보여서 불안할 때 매개변수를 바꾸어 확인해보겠다는 결정 — 이 모든 것이 분석 중에 스스로 내린 판단들이었다. Mission 14에서는 따라하기 바빴다면, Mission 15에서는 조금 더 직접 생각했다.

VVIP 30명을 찾았다고 분석이 끝난 것은 아니다. 그 30명이 왜 30명인지, 무엇이 그들을 그 자리에 있게 했는지, 그리고 70명의 승급 후보군이 실제로 VVIP가 되려면 카드사가 무엇을 해야 하는지는 더 깊이 고민하지 못했다. 솔직히 금융권 데이터를 두 번의 미션 과정으로 연달아 다루면서 좀 지친 것 같다. 게다가 아직도 남은 Mission 16(그래도 베이커리 데이터라 조금은 기대하는 중…)과 프로젝트가 있다. 스케줄 관리상 여기까지가 최선이다. 이에 분석을 여기에서 마친다.

Mission 15 | DA12기 4팀 전미정